

BD01

*SQL : Agrégation et partitionnement*

EPFC-ULB

# Fonctions d'agrégation

Les **fonctions** COUNT(), SUM(), MIN(), MAX() et AVG() permettent d'**agréger** des données.

C'est à dire **retourner un résultat pour un ensemble** de données (relation ou partition).

Employee

| <u>SSN</u> | FName | LName | Salary |
|------------|-------|-------|--------|
| 123        | John  | Doe   | 2000   |
| 456        | John  | Smith | 1700   |
| 789        | Paul  | Smith | 1900   |

Moyenne des salaires

```
SELECT AVG(e.Salary)
FROM Employee e
```

La requête SELECT SSN, MAX(Salary) FROM Employee est illégale.  
Pourquoi ?

# Fonctions d'agrégation

Employee

| <u>SSN</u> | FName | LName | Salary |
|------------|-------|-------|--------|
| 123        | John  | Doe   | 2000   |
| 456        | John  | Smith | 1700   |
| 789        | Paul  | Smith | 1900   |

Le nombre de prénoms différents

```
SELECT COUNT(DISTINCT FName)
FROM Employee e
```

Le maximum des salaires

```
SELECT MAX(Salary)
FROM Employee e
```

Le nombre d'employés

```
SELECT COUNT(*)
FROM Employee e
```

Toutes les lignes

## La clause GROUP BY

```
SELECT A1, ..., An, AGG(An+1), ..., AGG(An)
FROM ... WHERE ...
GROUP BY A1, ..., An
HAVING condition
```

Ordre intuitif d'évaluation :

Evaluation du FROM... WHERE...

Partitionnement selon les attributs du GROUP BY

Application de la condition du HAVING (sur les partitions)

Evaluation du SELECT

Moyenne des salaires pour les départements de moins de 3 employés

```
SELECT DNo, AVG(Salary)
FROM Employee
GROUP BY DNo
HAVING count(*) < 3
```

Employee

| SSN | Salary | DNo |
|-----|--------|-----|
| 123 | 2000   | 1   |
| 456 | 1700   | 2   |
| 789 | 1900   | 1   |
| 888 | 2100   | 2   |
| 999 | 3000   | 1   |

Deux partitions

| SSN | Salary | DNo |
|-----|--------|-----|
| 123 | 2000   | 1   |
| 789 | 1900   | 1   |
| 999 | 3000   | 1   |
| 456 | 1700   | 2   |
| 888 | 2100   | 2   |

Une seule a été retenue

| SSN | Salary | DNo |
|-----|--------|-----|
| 456 | 1700   | 2   |
| 888 | 2100   | 2   |

| DNo | AVG(Salary) |
|-----|-------------|
| 2   | 1900        |

# La clause GROUP BY : théorie

La clause **GROUP BY** <attributs> permet de **partitionner** une relation.

**Il y aura une partition par combinaison de valeurs des attributs.**

Syntaxe :

```

SELECT A1, ..., An, AGG(An+1), ..., AGG(An)
FROM ... WHERE ...
GROUP BY A1, ..., An
HAVING condition
    
```

Les attributs du SELECT (A1, ..., An) doivent être des clés de groupement (car uniques par groupe), ainsi que des agrégations obtenues en utilisant une fonction d'agrégation.

La condition du **HAVING** porte sur les expressions autorisées par SELECT.